🚦 CURSO OPENCLAW — AULA EXTRA

⚡ Seu agente trava? Provavelmente é isso

Rate *Limits*: Por que trava e como resolver

Entenda o 429, conheça os tiers da Anthropic e OpenAI, e aprenda as estratégias práticas para nunca mais ter seu agente parado por falta de cota.

DURAÇÃO	NÍVEL	PRÉ-REQ
12 min	**Intermediário**	**API Key ativa**

⛔ ERROR LOG

429 Too Many Requests

RateLimitError: Rate limit reached for claude-sonnet-4-5. Retrying in 32s…

01 O que é Rate Limit?

O provedor limita quantas requisições você pode fazer por unidade de tempo.

Rate limit é um mecanismo de proteção que todo provedor de API usa. Quando você ultrapassa a cota, a API recusa a chamada com o status `HTTP 429` — "Too Many Requests". Não é falha sua; é uma regra de infraestrutura que existe por boas razões:

MOTIVO 1

🏗️ Proteger infraestrutura

- Evitar sobrecarga dos servidores
- Garantir estabilidade da plataforma
- Prevenir abusos e DDoS acidentais

MOTIVO 2

🤝 Qualidade para todos

- Nenhum usuário monopoliza recursos
- SLA justo para toda a base
- Tiers refletem uso e comprometimento

📊 Os 3 tipos de limite

RPM
Requests Per Minute
Nº de chamadas por minuto — o mais comum

TPM
Tokens Per Minute
Volume de tokens (input + output) por minuto

RPD
Requests Per Day
Limite diário de chamadas (tier Free)

02 Como aparece no OpenClaw

O sinal mais óbvio é o 429 no log — mas nem sempre fica tão claro.

LOG

```
ERROR RateLimitError: 429 Too Many Requests
       at Anthropic.makeRequest (sdk/client.js:142)
WARN  Rate limit reached for model claude-sonnet-4-5
       x-ratelimit-remaining-requests: 0
       x-ratelimit-remaining-tokens: 0
       x-ratelimit-reset-requests: 60s
INFO  Retrying in 32s (attempt 1/3)…
```

🔍 Quando acontece mais

🕘 Muitos crons no mesmo horário

10 crons agendados para 9:00h disparam ao mesmo tempo → burst de RPM em segundos. O agente "trava" na hora do rush.

🤖 Sub-agents em paralelo

Cada sub-agent faz suas próprias chamadas. Três sub-agents rodando juntos = 3× a pressão no rate limit da mesma API Key.

💗 Heartbeats muito frequentes

Heartbeat configurado a cada 5 min com modelo pesado + contexto grande → acumula TPM rapidamente ao longo do dia.

03 Limites por Provedor

Conheça os tiers e saiba onde você está agora.

🟣 Anthropic (Claude)

TIER	RPM	TPM	RPD	REQUISITO
Free	5	25k	100	Conta criada
Build Tier 1	50	50k	1k	$5 gastos
Build Tier 2	1.000	160k	—	$50 gastos
Scale Tier 3	2.000	800k	—	$100 gastos
Scale Tier 4	4.000	2.4M	—	$250 gastos

🟢 OpenAI (GPT)

TIER	RPM	TPM	REQUISITO
Free	3	40k	Conta criada
Tier 1	500	200k	$5 gastos
Tier 2	5.000	2M	$50 gastos
Tier 3	10.000	4M	$100 gastos

📈 Como subir de tier

O tier sobe automaticamente conforme seu **gasto acumulado** ao longo do tempo. Não precisa pedir — a plataforma detecta e libera.

Free	$0		Início
Tier 1	≥ $5		Básico
Tier 2	≥ $50		Médio
Tier 3	≥ $100		Avançado

Tier 4	≥ $250		Scale

Fique atento ao Free tier

5 RPM significa que se você tiver 2 crons rodando juntos com 3 chamadas cada, você já vai bater o limite em segundos. Com conta nova, isso é o cenário mais comum de "agente travado".

04 Estratégias no OpenClaw

Quatro abordagens complementares — use a combinação certa pro seu nível de uso.

🔻 A) Reduzir Pressão

Antes de tentar qualquer outra coisa: gaste menos cota. Parece óbvio, mas a maioria dos problemas se resolve aqui.

⚡ Modelo mínimo para cada tarefa

Haiku para heartbeats e crons rotineiros — usa 10× menos tokens que Sonnet.
Sonnet para interação diária e tarefas com contexto médio.
Opus *somente* quando precisar de raciocínio profundo — nunca como padrão.

🕐 Espaçar os crons

Nunca agendar múltiplos crons para o mesmo horário exato. Distribua com pelo menos 5 minutos de intervalo:
`9:00` → resumo diário | `9:05` → checar emails | `9:10` → sync calendário

🤖 Evitar sub-agents em paralelo

Se uma tarefa pode ser feita em sequência, não dispare em paralelo. Cada sub-agent consome cota da mesma API Key. Prefira **serial** quando não há ganho real de velocidade.

🔄 B) Retry com Backoff Automático

O OpenClaw já cuida disso por você. Quando recebe um 429, o runtime espera e tenta novamente automaticamente.

1. **API retorna 429**
   Limite atingido — chamada rejeitada pelo provedor
2. **OpenClaw inicia backoff**
   Espera exponencial: 1s → 2s → 4s → 8s… até a janela resetar
3. **Retry automático — sem intervenção**
   A chamada é retentada. Você não precisa fazer nada.

Agente "lento" não é agente "travado"

Se você perceber que o agente demorou 30-60 segundos a mais para responder, provavelmente estava em backoff. Isso é comportamento *correto* — não é falha. O agente vai responder; só precisa aguardar.

📅 C) Distribuir Carga

Quando reduzir e esperar não bastam, a próxima fronteira é distribuir o trabalho no tempo e no espaço.

```yaml
# ❌ Evite: 3 crons no mesmo minuto
crons:
  - schedule: "0 9 * * *"
    name: resumo-diario
  - schedule: "0 9 * * *"
    name: checar-emails
  - schedule: "0 9 * * *"
    name: sync-calendario

# ✅ Prefira: distribuídos em 5 min
crons:
  - schedule: "0 9 * * *"
    name: resumo-diario
  - schedule: "5 9 * * *"          # 09:05
    name: checar-emails
  - schedule: "10 9 * * *"         # 09:10
    name: sync-calendario
```

🔒 Jobs pesados → sessionTarget: isolated

Use `sessionTarget: "isolated"` para sub-agents que fazem muitas chamadas. Isso garante que o job pesado não compete com as interações da sessão principal pelo mesmo rate limit window.

📡 D) Monitorar em Tempo Real

HEADER DE RESPOSTA	SIGNIFICADO	AÇÃO SE BAIXO
`x-ratelimit-remaining-requests`	Chamadas restantes na janela atual	Reduzir frequência
`x-ratelimit-remaining-tokens`	Tokens restantes na janela atual	Usar modelo menor
`x-ratelimit-reset-requests`	Tempo até RPM resetar	Aguardar backoff
`x-ratelimit-reset-tokens`	Tempo até TPM resetar	Aguardar backoff

✅ **Verifique seu tier no dashboard**

Anthropic:

console.anthropic.com → Settings → Limits |

OpenAI:

platform.openai.com → Settings → Limits

05 Diagnóstico Rápido

"Meu agente travou — é rate limit?"

🔍 Checklist de Diagnóstico

- [ ] Você tem **múltiplos crons agendados para o mesmo horário**?
- [ ] Tem **sub-agents rodando em paralelo** nessa sessão?
- [ ] O log menciona `429` ou `RateLimitError`?
- [ ] O agente **voltou a funcionar sozinho** após alguns minutos?
- [ ] Você está no tier Free ou Tier 1 com uso intenso?

🎯 **Se marcou 3 ou mais → quase certeza que é rate limit**

A solução mais rápida: espaçar os crons, usar Haiku no heartbeat, e aguardar o retry automático. Se persistir, verificar o tier e considerar aumentar o gasto acumulado.

06 Rate Limit e Custo

Esclarece uma confusão frequente — são duas coisas diferentes.

🚦

Rate Limit

Limita a **velocidade** das chamadas. Quando atingido, o agente espera. **Não aumenta o custo** — tokens de espera não existem. Apenas atrasa a execução.

💳

Billing Limit

Limita o **gasto** mensal. Configurável no dashboard. Quando atingido, as chamadas são bloqueadas até o ciclo resetar ou o limite ser aumentado.

429	402	$0
RATE LIMIT — ESPERE	BILLING LIMIT — PAGUE	CUSTO DO TEMPO ESPERANDO

💡 **Rate limit não te cobra nada a mais**

Você paga apenas pelos tokens que o modelo *processou*. O tempo em backoff não gera cobrança. Um agente que ficou 2 minutos em retry usou exatamente os mesmos tokens de um que respondeu em 10 segundos.

07 Dica Avançada: Múltiplas API Keys

Para uso intenso, distribuir entre chaves (ou provedores) é a saída.

🔑 Múltiplas chaves no mesmo provedor

Cada API Key tem seu próprio rate limit independente. Criar duas keys na Anthropic e rotacionar entre elas dobra o seu RPM efetivo. Funciona bem para workloads previsíveis.

🌐 Provedores diferentes por agente

Anthropic para agentes de produção críticos.
OpenAI como backup ou para tarefas específicas de código.
O OpenClaw suporta múltiplos providers nativamente — configure tokens distintos por agente.

CONFIG

```
# OpenClaw — configurar providers por agente
```

```
# Agente principal usa Anthropic
openclaw config set model anthropic/claude-sonnet-4-5

# Agente de backup configurado com OpenAI
# (via OPENAI_API_KEY no env ou config)
openclaw config set model openai/gpt-4o --agent backup-agent
```

🧠 **Regra prática**

Para 90% dos usuários do curso, o rate limit some depois de gastar $5 (Tier 1) e espaçar os crons. Múltiplas keys e multi-provider são para quem está escalando sério — não pule para isso primeiro.

✅ Checklist Anti-Rate-Limit

- [ ] Heartbeat usando `claude-haiku-4-5` (não Sonnet ou Opus)
- [ ] Crons distribuídos com ≥ 5 min de intervalo entre si
- [ ] Jobs pesados com `sessionTarget: "isolated"`
- [ ] Tier verificado em console.anthropic.com → Settings → Limits
- [ ] Billing limit configurado (não deixar ilimitado)

➡️ AULA RELACIONADA

N-7 — Quanto Custa e Qual Modelo Usar